

HITO 2 - HOTELES




Minería de Datos- Sección 1
Grupo: 9

Motivación y Objetivos

El Dataset **hotel_bookings** permite analizar variables como:

- Fechas
- Duración de estadias
- Precios
- Tipos de clientes
- Anticipación
- Canales de distribución



Dataset Post EDA:

Dataset

86940 registros, 30 variables, donde destacan:

- **is_canceled**
- **lead_time**
- **adr**
- **customer_type**
- **total_nights**

Importante!

Las reservas se hicieron en dos hoteles, uno tipo Resort y otro tipo City

Preguntas y Problemas abordados

1

¿Se puede predecir la cancelación de una reserva en base a mes de llegada, tipo de cliente, lead time y duración de estadía?

Variable objetivo: **is_canceled**

2

Analizar los pesos de los atributos con Lasso, ver si tiene sesgo (modelo con correlacion) y seleccionar los mejores.

Variable explicativa: **adr**

3

¿Existen grupos de reservas con características similares?

Variables utilizadas: **lead_time, adr, total_noches, adults y variables categóricas codificadas**



Propuesta metodológica Experimental



1

Clasificación: Predicción de cancelacion

- Modelos: **Regresión Logística** y **Random Forest**
- Variables: arrival_date_month, customer_type, lead_time, total_noches.
- Métricas: **ROC-AUC** y **matriz de confusión**.

2

Pesos de Atributos acorde a ADR


- Modelo: **Lasso por ADR**.
- Métrica: MAE

3

Clustering: Segmentación


- Algoritmo: **K-Means**
- Validación: **Silhouette Score**, **método del codo** y descripción de cada cluster (medianas y proporciones).
- K óptimo encontrado: 3 clusters.

Resultados Hito 1 (P1)




Random Forest

Resultados Hito 1 (P1)




Logistic Regression

Resultados Finales (P1)



Random Forest

Resultados Finales (P1)



Logistic Regression

Preprocesamiento y sus implicancias (P2)



- **StandardScaler** en numéricas por penalización de lasso
- **OneHotEncoder** para convertir categóricas, modelo lineal no puede trabajar con texto

Contras:

- Sube la dimensionalidad y la matriz queda sparse
- Los coeficientes de dummies se interpretan como efectos relativos (**pueden volverse inestables si hay categorías raras**)

Modelo y desempeño + por qué no “nos mata” la dimensionalidad

$R^2 = 0.816$, MAE = 19.47

191 features → Lasso dejó 87

Baseline (predecir el promedio): $R^2 \approx 0$, MAE = 39.08


Mejora vs baseline: MAE ↓ ~50% (39.08 → 19.47)

- Con split 80/20, el modelo explica ~82% de la variación del ADR y se equivoca en promedio ~19.5 unidades.
- Lasso ayuda con la alta dimensionalidad porque empuja muchos coeficientes a cero.
- La maldición sería crítica en modelos basados en distancia o si p fuera enorme versus n. Acá n es grande (32k) y p es 191, así que el principal efecto es más bien computacional e interpretativo, no que el modelo ‘colapse’.



Resultados (P2)

	feature	coef	abs_coef
21	arrival_date_month_August	92.682443	92.682443
25	arrival_date_month_July	72.835857	72.835857
155	market_segment_Complementary	-72.664788	72.664788
167	reserved_room_type_B	-53.938771	53.938771
35	meal_SC	-49.316349	49.316349
173	reserved_room_type_H	47.433350	47.433350
31	arrival_date_month_September	46.092294	46.092294
26	arrival_date_month_June	33.054048	33.054048
29	arrival_date_month_November	-30.183203	30.183203
18	hotel_City Hotel	-29.901722	29.901722
32	meal_BB	-28.231498	28.231498
83	country_GRC	25.914537	25.914537
172	reserved_room_type_G	25.621541	25.621541
24	arrival_date_month_January	-24.135355	24.135355
160	market_segment_Online TA	22.386249	22.386249
23	arrival_date_month_February	-21.654552	21.654552
182	assigned_room_type_I	-20.814577	20.814577
22	arrival_date_month_December	-19.866693	19.866693
166	reserved_room_type_A	-18.696469	18.696469
186	deposit type Refundable	18.573449	18.573449

- Principal patrón: **estacionalidad domina el ADR**
- Agosto y Julio aparecen con los mayores coeficientes positivos
- También pesan fuerte **variables comerciales** y de producto
- El heatmap es la correlación entre numéricas y ADR y muestra que **no hay una numérica que explique todo por sí sola**




Resultados (P3)



Visualización de Clusters

Resultados Preliminares (P3)



Método del codo

Conclusión

P1

- El modelo mejoró con la modificación, pero no fue suficiente.
- Probablemente mejoraría con un dataset más grande, con más atributos que entreguen información útil.

P2

- Lasso permitió identificar los atributos más influyentes en ADR, siendo:
 arrival_date_month_August
 arrival_date_month_July
Estas variables reflejan estacionalidad lo que tiene sentido, dado que en esa fecha allá es verano.

P3

- Se encontraron 3 segmentos de reservas con comportamientos distintos.
- El clustering fue aceptable lo que permitió que se infiriera que hay posibles factores o variables que influyen en el precio .